

TP1: Regresión e introducción a la evaluación de modelos

Predicción de demanda horaria de bicicletas compartidas: Bike Sharing Dataset (UCI)

Target: cnt (bicis/hora) **Validación:** K-Fold, k=5 **Métrica:** RMSE

Grupo 13:

Sofía Alfie

Augusto Frate

Facundo Juli

El problema y el flujo de trabajo

Objetivo: predecir `cnt` (bicicletas alquiladas por hora) a partir de variables climáticas y de calendario, usando modelos de regresión evaluados con validación cruzada.



Decisiones antes de modelar

1

Variables categóricas

8 variables (season, yr, mnth, hr, holiday, weekday, workingday, weathersit) son etiquetas, no magnitudes → One-Hot Encoding.

2

Valores faltantes

Verificado con `isnull().sum()`: 0 faltantes en todo el dataset. No hizo falta imputar.

3

Outliers (criterio IQR)


Se detectaron en windspeed y cnt, pero se decidió mantenerlos: son observaciones reales del sistema (alta demanda, viento fuerte), no errores.

4


Data leakage evitado

$\text{casual} + \text{registered} = \text{cnt}$ exactamente → se excluyeron. Igual que instant (ID) y dteday (redundante con yr/mnth/hr).

Cómo se ve la variable objetivo




cnt está muy sesgada a la derecha (media 189 > mediana 142): muchas horas de baja demanda y pocas de demanda muy alta.



Los outliers (círculos) se repiten en las 4 estaciones y son consistentes con eventos reales de alta demanda → se mantienen.

Por qué hr se trata como categórica



Dos picos, no una tendencia lineal

Pico mañana (~8hs): 359 bicis/hora en promedio — entrada laboral.

Pico tarde (~17-18hs): 461 bicis/hora — salida laboral, el máximo del día.

Valle de madrugada (~4hs): prácticamente sin demanda.

Un coeficiente lineal único para "hora" no puede capturar dos picos. One-Hot Encoding le da a cada hora un efecto propio.


Separación de datos y validación cruzada

Train / Test split



random_state=42 · el test queda reservado hasta el final: no participa en limpieza, k-fold, ni selección de hiperparámetros.

K-Fold Cross-Validation (k=5) — sólo sobre train



RMSE — diagnóstico bias / variance

Train $\approx$ Val, ambos altos → underfitting

Train bajo, Val alto → overfitting

Train $\approx$ Val, ambos bajos → generaliza bien

Regresión lineal (base): RMSE train 101.86 / val 102.39 — valores parecidos pero altos → **underfitting**.

Esto motiva pasar a un modelo más flexible: regresión polinómica.


102.39

RMSE de validación con regresión lineal simple — el punto de partida a superar

Comparación de modelos (RMSE de validación)

Modelo	Grado	λ (lambda)	RMSE train	RMSE val
Regresión lineal	—	—	101.86	102.39
Polinómica	2	—	100.64	101.26
Polinómica	3	—	98.58	99.35
Polinómica + Lasso	3	1.0	104.43	104.83
Polinómica + Lasso	3	10.0	153.96	154.05

★ *Mejor RMSE de validación: Polinómica grado 3, sin regularizar. Gap train/val mínimo (~0.77) → mejora real, no memorización.*



Respondiendo la consigna 5

¿Qué modelo obtuvo menor error?

Regresión polinómica de grado 3 sin regularizar: RMSE de validación = 99.35 (en contraste de 102.39 lineal y 101.26 grado 2).

¿Cuál elegirían para producción?

También grado 3 sin regularizar. Mejora real (no memoriza el train, gap ~ 0.77) y Lasso solo agregó sesgo (no había overfitting que corregir).

¿Qué RMSE esperan en producción?

Se evaluó el modelo elegido (grado 3, sin regularizar) reentrenando con TODO X_{train} , una única vez, sobre X_{test} .

97.58

RMSE final sobre test (bicis/hora)

Conclusión

El modelo de grado 3 presenta el mejor desempeño en validación.

El RMSE de test (97.58) fue consistente con la estimación del k-fold (99.35), lo que respalda la elección del modelo y su capacidad de generalización.

Muchas gracias